




Grupo 09

Sumarizador de Notícias da Copa do Mundo 2026



FIFA



Sumário


1. Introdução e Objetivos
2. Pipeline passo a passo
3. Implementações chave
4. Exemplo de execução e saída
5. Análise produzida
6. Limitações e melhorias possíveis

Introdução e Objetivos

Sumarização extrativa multi-documento entre diferentes portais de notícias sobre Copa do Mundo, para gerar um resumo curto e não-redundante sobre o mesmo jogo, usando grafos e PageRank implementados do zero.



Pipeline passo a passo



Leitura e
segmentação de
frases

PageRank
ponderado via
método das
potências

Geração da saída
em **Markdown**

Cálculo de
similaridade
entre frases e
construção de
matriz de
adjacência

Seleção das n
frases por **score**
com anti-
redundância

Implementações chave

Pré-processamento NLP

Tokenização de frases, stopwords PT e stemmer RSLP via NLTK, única biblioteca externa

Max Heap

Fila de prioridade para selecionar frases por score

Calculo de similaridade

Similaridade entre frases baseada em tokens stemmed (sem TF-IDF)

Grafo (matriz de adjacência)

Grafo ponderado que armazena peso da similaridade entre frases.

PageRank Ponderado

Método das potências implementado do zero, retornando histórico de convergência

Tabela Hash

Mapeia id_frase → id_arquivo para citar fonte no resumo

Exemplo de execução e saída

O sistema foi testado com o conjunto de dados jogo01, composto por notícias sobre um clássico entre Brasil e Argentina na Copa do Mundo extraídas de três portais diferentes (GE, ESPN e UOL). O comando disparado solicitou um resumo com o tamanho limite de 6 frases.

O programa processou um total de 29 frases, mapeou o grafo de interconexões textuais e retornou uma taxa de compressão de 0.207 (apenas 20,7% do texto original foi mantido).

```
--- Frases selecionadas para o resumo ---
```

1. [09] (ge.txt) O Brasil venceu a Argentina por 2 a 1 nesta quinta-feira, em partida válida pela fase de grupos da Copa do Mundo.
2. [11] (ge.txt) O primeiro gol da seleção brasileira foi marcado por Vinicius Junior, aos 15 minutos do primeiro tempo, após assistência de Neymar.
3. [06] (espn.txt) O Brasil agora se prepara para enfrentar a França na próxima terça-feira, em jogo decisivo pela classificação.
4. [12] (ge.txt) A Argentina empatou o jogo no início do segundo tempo, com um gol de pênalti convertido por Messi.
5. [24] (uol.txt) Com a vitória, a seleção brasileira soma seis pontos e assume a liderança do grupo.
6. [18] (ge.txt) Os jogadores brasileiros comemoraram o resultado no vestiário, com declarações otimistas sobre o restante do torneio.

Análise produzida

Mapeamento de Hubs Semânticos

A aresta de maior peso no grafo (1.556) conecta a frase da ESPN à frase do GE sobre o gol de pênalti do Messi. Por haver uma redundância natural entre as três fontes de notícias, as frases que tratam dos eventos centrais (Gols, Vitória, Próximo Jogo e Classificação) criam agrupamentos fortemente conectados (painéis ou cliques) no grafo.

Distribuição do Score

A frase [09] obteve o maior score de PageRank (1.5093) porque ela resume o fato principal da notícia. Muitas outras frases do texto fazem referência ao Brasil, à Argentina ou ao placar, fazendo com que o fluxo de importância do grafo convergisse massivamente para ela.

Qualidade do Resumo Coletado

Analisando a saída de forma lógica, o PageRank conseguiu montar uma linha do tempo quase perfeita do jogo: contextualizou o placar [09], explicou o primeiro gol [11], o empate [12], o desfecho do campeonato [24], a comemoração [18] e o próximo compromisso [06]

Limitações e Melhorias Possíveis

Omissão de Fatos
por Divisão de Votos
(O Problema do Gol
do Rodrygo)

Dependência de
Repetição de
Palavras Exatas

Normalização
Semântica (Word
Embeddings)

Filtro de
Diversificação Prévio
à Seleção (MMR)